

**CÁSSIO RODRIGUES ALVES**

**MYCELIUM AI: INFERENCE-TIME PLASTICITY IN DECENTRALIZED NEURAL  
ARCHITECTURES**

**Brasil  
2026**

---

## RESUMO

Este trabalho apresenta o Mycelium AI, uma arquitetura neural que redefine a fronteira entre treinamento e inferência. Inspirada nas redes miceliais biológicas — descentralizadas, adaptativas e capazes de aprendizagem local contínua — a abordagem proposta introduz a plasticidade durante a inferência: a capacidade do estado interno evoluir à medida que os dados fluem pelo sistema, sem exigir retropropagação global ou atualizações de pesos. A inovação central reside em um sistema de parâmetros de duplo estado, separando parâmetros pedra estáveis (pesos persistentes de evolução lenta) da memória areia volátil (memória decainte dependente de contexto). Cada nodo hyphal mantém estado adaptativo local, permitindo adaptação limitada e regulada durante passos forward. O trabalho demonstra que a arquitetura alcança adaptação estável sem esquecimento catastrófico, não requer computação de gradiente durante a inferência e exibe propriedades emergentes incluindo auto-organização e roteamento sensível a contexto.

**Palavras-chave:** Aprendizagem Durante Inferência. Arquiteturas Descentralizadas. Inteligência Artificial Bioinspirada. Plasticidade Local. Redes Miceliais.

## ABSTRACT

This paper presents Mycelium AI, a neural architecture that fundamentally redefines the boundary between training and inference. Inspired by biological mycelial networks — decentralized, adaptive, and capable of continuous local learning — the proposed approach introduces inference-time plasticity: the ability of internal state to evolve as data flows through the system, without requiring global backpropagation or weight updates. The core innovation lies in a dual-state parameter system, separating stable stone parameters (slow-evolving persistent weights) from volatile sand memory (context-dependent decaying memory). Each hyphal node maintains local adaptive state, enabling bounded, regulated adaptation during forward passes. The work demonstrates that the architecture achieves stable adaptation without catastrophic forgetting, requires no gradient computation during inference, and exhibits emergent properties including self-organization and context-sensitive routing.

**Keywords:** Inference-Time Learning. Decentralized Architectures. Biologically-Inspired AI. Local Plasticity. Mycelial Networks.

## 1 INTRODUÇÃO

O paradigma dominante em aprendizagem de máquina repousa sobre uma dicotomia fundamental: modelos são treinados através de otimização global e, posteriormente, implantados com parâmetros congelados. Esta separação, embora computacionalmente conveniente, impõe limitações severas. Modelos não podem se adaptar a novas informações sem retreinamento, não podem aprender com exemplos individuais em tempo real e não podem refinar sua compreensão baseada no contexto durante a inferência.

Este trabalho desafia esta dicotomia buscando inspiração em uma fonte pouco convencional: as redes miceliais que formam a "wood wide web" sob o solo das florestas. Estas redes fúngicas exibem propriedades notáveis que contrastam fortemente com as redes neurais contemporâneas: adaptação local descentralizada, aprendizagem contínua durante operação, mudanças de estado local sem coordenação global e fluxo de informação análogo ao transporte de nutrientes.

## 1.1 DEFINIÇÃO FORMAL

Uma arquitetura neural exibe plasticidade durante inferência se seu estado interno  $S_t$  no tempo  $t$  evolui de acordo com:

$$S_{t+1} = f(S_t, x_t; \theta)$$

onde  $x_t$  é a entrada no tempo  $t$ ,  $\theta$  representa parâmetros arquiteturais fixos, e  $f$  é uma função de atualização local que não requer computação de gradiente com respeito a uma perda global.

## 1.2 CONTRIBUIÇÕES

Este artigo apresenta as seguintes contribuições:

**A Dualidade Pedra-Areia:** Introdução de uma separação formal entre parâmetros estáveis ( $W_{\text{stone}}$ ) e memória volátil ( $W_{\text{sand}}$ ), permitindo adaptação local limitada sem otimização global.

**Regras de Plasticidade Local:** Derivação de regras de atualização que operam inteiramente durante passos forward, não exigindo retropropagação ou armazenamento de gradiente durante inferência.

**Arquitetura Descentralizada:** Apresentação de uma topologia de rede inspirada na geometria micelial, onde nodos se comunicam através de passagem local de mensagens.

**Framework Teórico:** Estabelecimento de condições sob as quais a plasticidade durante inferência permanece estável e limitada.

## 2 A ARQUITETURA MYCELIUM

A arquitetura Mycelium comprehende nodos hyphais interconectados organizados em uma topologia descentralizada. Cada nodo mantém parâmetros de duplo estado e comunica com vizinhos através de passagem local de mensagens.

### 2.1 NODOS HYPHALIS

Um nodo hyphal  $h_i$  é a unidade computacional fundamental. Diferente de neurônios tradicionais que computam funções estáticas, nodos hyphais mantêm estado interno que evolui durante inferência:

$$h_i^{(t+1)} = \sigma \left( W_{\text{stone}}^{(i)} \cdot x_i^{(t)} + W_{\text{sand}}^{(i,t)} \cdot x_i^{(t)} + b_i \right)$$

onde  $W_{\text{stone}}^{(i)}$  representa parâmetros estáveis de evolução lenta (treináveis durante fases de treinamento), e  $W_{\text{sand}}^{(i,t)}$  representa memória volátil que atualiza durante cada passo forward.

## 2.2 A REGRA DE ATUALIZAÇÃO DA AREIA

A inovação chave que habilita plasticidade durante inferência é a regra de atualização da areia. Durante cada passo forward, a memória areia atualiza baseada em padrões de atividade local:

$$W_{\text{sand}}^{(t+1)} = \gamma \cdot W_{\text{sand}}^{(t)} + \eta \cdot \text{clip} \left( \frac{x^{(t)} \otimes x^{(t)}}{\|x^{(t)}\|^2 + \epsilon}, -\delta, \delta \right)$$

onde  $\gamma \in (0,1)$  é o fator de decaimento,  $\eta$  é a taxa de aprendizagem local,  $\delta$  é o limite de clipping, e  $\epsilon$  é uma constante para estabilidade numérica.

## 2.3 O MECANISMO META-NERVO

Para regular plasticidade, cada nodo inclui um meta-nervo — uma pequena rede de controle que modula atualizações de areia baseadas na incerteza de predição:

$$g_i^{(t)} = \sigma \left( \text{MLP} \left( \text{Var}(h_i^{(t)}) \right) \right)$$

O gate  $g_i^{(t)}$  escala a taxa de aprendizagem da areia: alta incerteza aumenta plasticidade (exploração), enquanto baixa incerteza a reduz (exploitação).

### 3 TRABALHOS RELACIONADOS

O Mycelium AI ocupa uma posição distinta no panorama de arquiteturas neurais. Esta seção contrasta a abordagem proposta com quatro paradigmas principais.

#### 3.1 TRANSFORMERS

Transformers (VASWANI et al., 2017) utilizam mecanismos de atenção para roteamento de informação, porém mantêm parâmetros congelados durante inferência. O Mycelium AI é ortogonal ao mecanismo de atenção — a distinção chave não é como a informação flui, mas como os parâmetros evoluem.

#### 3.2 REDES NEURAIS RECORRENTES

RNNs (HOCHREITER; SCHMIDHUBER, 1997) mantêm estado oculto através de passos de tempo. Porém, este estado representa ativações, não parâmetros. A memória areia do Mycelium modifica os pesos efetivos, não apenas as ativações.

#### 3.3 META-APRENDIZAGEM

Meta-aprendizagem (FINN; ABBEEL; LEVINE, 2017) habilita adaptação rápida através de inicializações otimizadas. Porém, requer fronteiras explícitas de tarefa e computação de gradiente durante adaptação. O Mycelium adapta continuamente sem definições de tarefa ou otimização de loop interno.

#### 3.4 UM NOVO EIXO DE DESIGN

Argumenta-se que o Mycelium AI abre um novo eixo no design de arquiteturas neurais. Enquanto arquiteturas existentes exploram como a informação flui (profundidade, largura, atenção, recorrência), o Mycelium explora como os parâmetros evoluem — um espaço de design fundamentalmente diferente.

### 4 FRAMEWORK FORMAL

Esta seção apresenta o framework matemático formal subjacente ao Mycelium AI.

#### 4.1 PRELIMINARES

Seja  $G = (V, E)$  um grafo representando a rede micelial, onde  $V = \{v_1, \dots, v_n\}$  são nodos hyphais e  $E \subseteq V \times V$  são conexões. Cada nodo  $v_i$  possui:

Parâmetros pedra:  $W_{\text{stone}}^{(i)} \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$

Memória areia:  $W_{\text{sand}}^{(i,t)} \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$

Ativação:  $h_i^{(t)} \in \mathbb{R}^{d_{\text{out}}}$

Gate meta-nervo:  $g_i^{(t)} \in [0, 1]$

## 4.2 TEOREMA: MEMÓRIA AREIA LIMITADA

**Teorema 4.1.** Dado decaimento  $\gamma \in (0, 1)$ , clipping  $\delta > 0$ , e taxa de aprendizagem  $\eta > 0$ , a memória areia em qualquer nodo permanece limitada:

$$\|W_{\text{sand}}^{(i,t)}\|_{\infty} \leq \frac{\eta\delta}{1 - \gamma} \quad \forall t \geq 0, \forall i \in \mathcal{V}$$

*Demonstração.* A atualização de areia é um mapeamento de contração devido a  $\gamma < 1$ , e o clipping garante que cada incremento é limitado por  $\eta\delta$ . A série geométrica converge ao limite declarado. ■

## 4.3 TEOREMA: MAPEAMENTO DE CONTRAÇÃO

**Teorema 4.2.** O operador de atualização da areia  $T$  é uma contração com constante de Lipschitz  $\gamma < 1$ :

$$\|\mathcal{T}(W_1) - \mathcal{T}(W_2)\| = \gamma \|W_1 - W_2\|$$

Como  $\gamma < 1$ , pelo Teorema do Ponto Fixo de Banach, aplicações repetidas convergem para um único ponto fixo.

## 5 IMPLEMENTAÇÃO

Esta seção descreve os aspectos práticos de implementação da arquitetura Mycelium AI.

## 5.1 DIRETRIZES DE HIPERPARÂMETROS

Baseado em análise teórica e validação empírica, recomenda-se as seguintes faixas:

Parâmetro	Símbolo	Faixa Recomendada
Fator de decaimento	$\gamma$	0.95 — 0.995
Taxa de aprendizagem	$\eta$	0.001 — 0.01
Limite de clipping	$\delta$	0.1 — 0.5
Grau do nodo	$k$	4 — 8

## 5.2 COMPLEXIDADE COMPUTACIONAL

A complexidade por camada corresponde a redes feedforward padrão, com a atualização de areia adicionando apenas um overhead de fator constante:

Multiplicação de matriz:  $O(n \cdot d^2)$

Atualização de areia:  $O(d^2)$

Meta-nervo:  $O(d)$

Total por camada:  $O(n \cdot d^2)$

## 6 DISCUSSÃO

### 6.1 PROPRIEDADES EMERGENTES

A natureza descentralizada e adaptativa das redes Mycelium dá origem a propriedades emergentes:

**Auto-Organização:** Caminhos de alto tráfego naturalmente se fortalecem à medida que areia acumula ao longo de rotas frequentemente usadas.

**Aprendizagem Contínua:** O mecanismo de decaimento  $\gamma < 1$  naturalmente previne esquecimento catastrófico.

**Exploração Guiada por Curiosidade:** O mecanismo meta-nervo cria um sinal de motivação intrínseco.

## 6.2 LIMITAÇÕES

Reconhecem-se as seguintes limitações: (1) overhead computacional de aproximadamente 20-30% comparado a camadas feedforward padrão; (2) inferência não-determinística devido a atualizações stateful de areia; (3) garantias teóricas mais amplas de convergência permanecem questões abertas.

## 6.3 TRABALHOS FUTUROS

Direções promissoras incluem: redes Mycelium hierárquicas com múltiplas escalas, extensões multimodais com tipos hyphais especializados, conexões mais profundas com biologia micelial real, e exploração de hardware neuromórfico para implementação eficiente.

## 7 CONCLUSÃO

Este trabalho apresentou o Mycelium AI, uma arquitetura neural que reimagina fundamentalmente a relação entre treinamento e inferência. Ao separar parâmetros pedra estáveis da memória areia volátil, habilitou-se plasticidade local limitada durante inferência sem retropropagação global.

Este não é uma melhoria incremental a arquiteturas existentes, mas um novo eixo de design — que troca otimização global por adaptação local, parâmetros congelados por aprendizagem contínua, e controle centralizado por emergência descentralizada.

Convida-se a comunidade de pesquisa a explorar este novo espaço de design e descobrir quais capacidades emergem destas raízes bioinspiradas.

## REFERÊNCIAS

- CARPENTER, G. A.; GROSSBERG, S. A massively parallel architecture for a self-organizing neural pattern recognition machine. **Computer Vision, Graphics, and Image Processing**, v. 37, n. 1, p. 54-115, 1987.
- FINN, C.; ABBEEL, P.; LEVINE, S. Model-agnostic meta-learning for fast adaptation of deep networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. **Proceedings** [...]. Sydney: PMLR, 2017. p. 1126-1135.
- GRAVES, A.; WAYNE, G.; DANIHELKA, I. Neural turing machines. **arXiv preprint arXiv:1410.5401**, 2014.
- HEBB, D. O. **The Organization of Behavior**: a neuropsychological theory. New York: Wiley, 1949.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735-1780, 1997.
- SIMARD, S. W. et al. Net transfer of carbon between ectomycorrhizal tree species in the field. **Nature**, v. 388, n. 6642, p. 579-582, 1997.
- VASWANI, A. et al. Attention is all you need. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. **Proceedings** [...]. Long Beach: Curran Associates, 2017. p. 5998-6008.